



Τμήμα Εφαρμοσμένης Πληροφορικής

Εργασία στο μάθημα Μηχανική Μάθηση

**«Classification Models για την Πρόβλεψη Χρεοκοπίας:
Συγκριτική Μελέτη»**

Τιντικάκη Καλλιόπη Μαρία ics23088

Κουιμτζίδου Ιορδάνα iis23049

Κενανίδου Σωτηρία iis23162

Τσιμπίνη Πετρούλα ics23085

Ιανουάριος 2026

Πίνακας Περιεχομένων

1. Εισαγωγή	4
2. Σχετική Βιβλιογραφία	4
3. Περιγραφή Data Set	5
3.1. Γενική Περιγραφή	5
3.2. Δομή και μεταβλητές του dataset	6
3.3 Κατανομή επιχειρήσεων ανά έτος	6
3.4 Στατιστική ανάλυση χρηματοοικονομικών δεικτών	7
3.5. Συνοπτική Αποτίμηση του dataset	9
4. Προεπεξεργασία Δεδομένων	10
4.1. Έλεγχος και Αντιμετώπιση Ελλειπουσών Τιμών	10
4.2. Κανονικοποίηση και Κλιμάκωση Χαρακτηριστικών	10
5. Προτεινόμενη Μεθοδολογία	11
5.1. Χρήση του Stratified K-Fold και του Cross Validation	11
5.2 Εξισορρόπηση του Συνόλου Εκπαίδευσης	11
5.3 Αποτελέσματα Εξισορρόπησης ανά Fold	12
5.4 Οπτικοποίηση Κατανομής Κλάσεων	13
5.5 Αλγόριθμοι ταξινόμησης	14
5.6 Διαδικασία Εκπαίδευσης και Αξιολόγησης	15
5.7 Χαρακτηριστικά Εισόδου και Υπολογιστικό Περιβάλλον	19
6. Πειραματικά αποτελέσματα	20
6.1 Επεξεργασία Αρχείου Αποτελεσμάτων	20
6.2 Σύγκριση μοντέλων με Pivot Tables	21
6.3 Οπτικοποίηση Αποτελεσμάτων	21
6.4 Έλεγχος Περιορισμών Απόδοσης	22
6.5 Στατιστική Εγκυρότητα Σύγκρισης Μοντέλων	22
7. Συμπεράσματα	23
8. Βιβλιογραφικές αναφορές	24

Πίνακας Εικόνων

Εικόνα 3.1: Αριθμός υγιών και πτωχευμένων επιχειρήσεων ανά έτος.....	7
Εικόνα 3.2: Ελάχιστες, μέγιστες και μέσες τιμές των χρηματοοικονομικών δεικτών για τις υγιείς επιχειρήσεις.....	8
Εικόνα 3.3: Ελάχιστες, μέγιστες και μέσες τιμές των χρηματοοικονομικών δεικτών για τις πτωχευμένες επιχειρήσεις.....	9
Εικόνα 5.1: Αναλογίες των κλάσεων σε κάθε fold στο αρχικό training set.....	11
Εικόνα 5.2: Ομοιόμορφη κατανομή των κλάσεων σε όλα τα folds λόγω της μεθοδολογίας stratified split, γεγονός που επιβεβαιώνει τη σταθερότητα της διαδικασίας.....	12
Εικόνα 5.3: Σύγκριση του πλήθους δειγμάτων ανά κλάση στο Training Set πριν και μετά την εξισορρόπηση.....	13
Εικόνα 5.4: Ενδεικτικός πίνακας σύγχυσης για το μοντέλο Linear Discriminant Analysis (LDA), όπως παράγεται αυτόματα κατά την εκτέλεση του κώδικα.....	18
Εικόνα 6.1 Οι μέσες τιμές Recall και Specificity στο test set.....	21
Εικόνα 6.2 Το καλύτερο μοντέλο, αυτό με το υψηλότερο μέσο όρο στο F1 Score.....	22

1. Εισαγωγή

Η παρούσα εργασία έχει ως αντικείμενο την ανάλυση και την πρόβλεψη της οικονομικής υγείας επιχειρήσεων, με στόχο τον εντοπισμό εκείνων που πρόκειται να κηρύξουν χρεοκοπία. Για τον σκοπό αυτό αξιοποιείται ένα σύνολο δεδομένων που περιλαμβάνει χρηματοοικονομικούς δείκτες απόδοσης, δείκτες δραστηριότητας, καθώς και πληροφορίες σχετικά με την κατάσταση κάθε εταιρείας (υγιής ή πτωχευμένη) και το έτος αναφοράς των μετρήσεων. Κάθε γραμμή του συνόλου δεδομένων αντιστοιχεί σε μία διαφορετική εταιρεία.

Στο πλαίσιο της εργασίας υλοποιείται ολοκληρωμένη διαδικασία ανάλυσης δεδομένων και μηχανικής μάθησης, η οποία περιλαμβάνει τον έλεγχο για ελλείψεις τιμές, την κανονικοποίηση των χαρακτηριστικών, καθώς και την αντιμετώπιση της ανισορροπίας μεταξύ υγιών και πτωχευμένων επιχειρήσεων. Η αξιολόγηση των μοντέλων πραγματοποιείται με χρήση τεχνικής Stratified k-fold cross-validation, ώστε να διασφαλιστεί ότι η κατανομή των κλάσεων διατηρείται στα σύνολα εκπαίδευσης και ελέγχου.

Βασικός στόχος της εργασίας είναι η συγκριτική αξιολόγηση διαφορετικών αλγορίθμων ταξινόμησης ως προς την ικανότητά τους να προβλέπουν με ακρίβεια τη χρεοκοπία των επιχειρήσεων. Συγκεκριμένα, εξετάζονται τόσο γραμμικά όσο και μη γραμμικά μοντέλα, και η απόδοσή τους μετράται με χρήση καθιερωμένων μετρικών αξιολόγησης, όπως Accuracy, Precision, Recall, F1-score και ROC-AUC, τόσο στο σύνολο εκπαίδευσης όσο και στο σύνολο ελέγχου.

Ακόμη, η εργασία στοχεύει στον έλεγχο για το κατά πόσο τα εξεταζόμενα μοντέλα μπορούν να ικανοποιήσουν συγκεκριμένους επιχειρησιακούς περιορισμούς απόδοσης, όπως η επίτευξη ελάχιστου ποσοστού επιτυχούς εντοπισμού πτωχευμένων και μη πτωχευμένων εταιρειών. Μέσα από τη συστηματική καταγραφή και σύγκριση των αποτελεσμάτων, επιδιώκεται η ανάδειξη του καταλληλότερου μοντέλου ταξινόμησης για το συγκεκριμένο πρόβλημα, καθώς και η εξαγωγή συμπερασμάτων που μπορούν να αξιοποιηθούν σε πραγματικές εφαρμογές ανάλυσης οικονομικού κινδύνου.

2. Σχετική Βιβλιογραφία

Η ανάλυση της οικονομικής κατάστασης των επιχειρήσεων απασχολεί ανέκαθεν τη χρηματοοικονομική επιστήμη καθώς και την αναλυτική δεδομένων ενώ στοχεύει στην πρόβλεψη της χρεοκοπίας. Η έγκαιρη αξιολόγηση της οικονομικής υγείας μιας επιχείρησης θεωρείται ιδιαίτερα σημαντική, καθώς μπορεί να υποστηρίξει τη διαδικασία λήψης αποφάσεων από επενδυτές, πιστωτικά ιδρύματα και ελεγκτικούς φορείς, αλλά και από τη διοίκηση, τους εργαζομένους και τους συνεργάτες μιας επιχείρησης.

Μία από τις πρώτες συστηματικές προσεγγίσεις στο πρόβλημα της πρόβλεψης πτώχευσης παρουσιάστηκε από τον Altman το 1968, με την ανάπτυξη του μοντέλου Z-Score, το οποίο βασίστηκε στη Διακριτική Ανάλυση (Linear Discriminant Analysis – LDA). Το μοντέλο αυτό κατέδειξε ότι ένας συνδυασμός πέντε χρηματοοικονομικών δεικτών μπορεί να χρησιμοποιηθεί για τον διαχωρισμό υγιών και πτωχευμένων επιχειρήσεων με ικανοποιητικά αποτελέσματα. Αργότερα, το 1980, ο Ohlson εισήγαγε τη Λογιστική Παλινδρόμηση (Logistic Regression), η οποία επέτρεψε την άμεση εκτίμηση της πιθανότητας πτώχευσης και αποτέλεσε εναλλακτική προσέγγιση με διαφορετικά πλεονεκτήματα σε σχέση με την LDA.

Με την εξέλιξη της υπολογιστικής ισχύος, η σχετική βιβλιογραφία στράφηκε προς τεχνικές Μηχανικής Μάθησης, οι οποίες μπορούν να διαχειριστούν πιο αποτελεσματικά πολύπλοκες και μη γραμμικές σχέσεις στα δεδομένα. Σε αυτό το πλαίσιο, οι Min και Lee (2005) έδειξαν ότι τα Support Vector Machines (SVM) παρουσιάζουν βελτιωμένη προβλεπτική απόδοση σε σύγκριση με παραδοσιακές στατιστικές μεθόδους.

Πιο πρόσφατες μελέτες εστιάζουν στις μεθόδους συνόλου (Ensemble Methods). Οι Zhang και Ma (2021) εφάρμοσαν αλγορίθμους όπως τα Random Forests και το Gradient Boosting σε οικονομικά δεδομένα και έδειξαν ότι οι μέθοδοι αυτές μπορούν να διαχειριστούν αποτελεσματικά ανισόρροπα σύνολα δεδομένων, τα οποία εμφανίζονται συχνά στο πρόβλημα της πρόβλεψης πτώχευσης.

Αντίστοιχο ενδιαφέρον παρατηρείται και στην ελληνική βιβλιογραφία. Ο Δασκαλόπουλος (2021), σε μελέτη που πραγματοποιήθηκε στο Πανεπιστήμιο Πειραιώς, ανέλυσε χρηματοοικονομικούς δείκτες ελληνικών επιχειρήσεων και ανέδειξε τη σημασία των δεικτών ρευστότητας στην πρόβλεψη οικονομικής δυσχέρειας. Παρόμοια, η Βρίκου (2021), στο Πανεπιστήμιο Μακεδονίας, χρησιμοποίησε λογιστικά δεδομένα για την πρόβλεψη οικονομικής δυσχέρειας, επισημαίνοντας τη σημασία των θεμελιωδών μεγεθών.

3. Περιγραφή Data Set

3.1. Γενική Περιγραφή

Το σύνολο δεδομένων που χρησιμοποιήθηκε στην παρούσα εργασία παρέχεται στο αρχείο Dataset2Use_Assignment1.xlsx και αφορά οικονομικά στοιχεία επιχειρήσεων σε διαφορετικά έτη. Κάθε γραμμή του dataset αντιστοιχεί σε μία εταιρεία για ένα συγκεκριμένο έτος αναφοράς, ενώ κάθε στήλη περιγράφει κάποιο χαρακτηριστικό ή δείκτη που σχετίζεται με την οικονομική της κατάσταση.

Στόχος της ανάλυσης είναι η πρόβλεψη της μελλοντικής κατάστασης μιας επιχείρησης, και συγκεκριμένα η διάκριση μεταξύ υγιών επιχειρήσεων και επιχειρήσεων που έχουν κηρύξει χρεωκοπία, γεγονός που καθιστά το πρόβλημα, πρόβλημα δυαδικής ταξινόμησης.

3.2. Δομή και μεταβλητές του dataset

Το dataset αποτελείται από διαφορετικές κατηγορίες μεταβλητών που περιγράφουν την οικονομική κατάσταση και τη δραστηριότητα των επιχειρήσεων. Συγκεκριμένα, περιλαμβάνει οκτώ χρηματοοικονομικούς δείκτες απόδοσης (στήλες A–H), οι οποίοι αποτυπώνουν βασικές πτυχές της οικονομικής ευρωστίας των εταιρειών. Επιπλέον, περιέχονται τρεις δείκτες δραστηριότητας (στήλες I–K), οι οποίοι είναι δυαδικές μεταβλητές και περιγράφουν χαρακτηριστικά που σχετίζονται με τη λειτουργική δραστηριότητα των επιχειρήσεων.

Η μεταβλητή στόχος (label) εκφράζει την τελική κατάσταση κάθε επιχείρησης και λαμβάνει την τιμή 1 για τις υγιείς επιχειρήσεις και την τιμή 2 για τις επιχειρήσεις που έχουν κηρύξει χρεωκοπία. Τέλος, το dataset περιλαμβάνει και μεταβλητή έτους, η οποία δηλώνει το χρονικό πλαίσιο στο οποίο αναφέρονται τα οικονομικά μεγέθη κάθε εγγραφής.


Ο συνδυασμός αριθμητικών και δυαδικών μεταβλητών, καθώς και η ύπαρξη χαρακτηριστικών σε διαφορετικές κλίμακες τιμών, καθιστούν απαραίτητη την εφαρμογή κατάλληλων τεχνικών προεπεξεργασίας πριν την εκπαίδευση αλγορίθμων μηχανικής μάθησης.

3.3 Κατανομή επιχειρήσεων ανά έτος

Στο Σχήμα 1 παρουσιάζεται ο αριθμός των υγιών και των πτωχευμένων επιχειρήσεων για κάθε έτος που περιλαμβάνεται στο dataset. Παρατηρείται ότι σε όλα τα εξεταζόμενα έτη οι υγιείς επιχειρήσεις υπερτερούν σημαντικά αριθμητικά σε σχέση με τις πτωχευμένες, γεγονός που υποδηλώνει έντονη ανισορροπία μεταξύ των δύο κλάσεων. Επιπλέον, διαπιστώνεται ότι το έτος 2009 εμφανίζει μειωμένο συνολικό αριθμό επιχειρήσεων σε

σύγκριση με τα προηγούμενα έτη, ενώ το 2008 παρουσιάζει σχετικά αυξημένο αριθμό πτωχευμένων επιχειρήσεων συγκριτικά με τα υπόλοιπα έτη.

Η παρατηρούμενη ανισορροπία κλάσεων αποτελεί κρίσιμο παράγοντα για το πρόβλημα της πρόβλεψης χρεωκοπίας, καθώς ενδέχεται να οδηγήσει τα μοντέλα ταξινόμησης σε μεροληπτική συμπεριφορά υπέρ της πλειοψηφικής κλάσης. Για τον λόγο αυτό, η συγκεκριμένη ιδιαιτερότητα του dataset λαμβάνεται υπόψη κατά τον σχεδιασμό της πειραματικής διαδικασίας και την αξιολόγηση των μοντέλων.



Εικόνα 3.1 Αριθμός υγιών και πτωχευμένων επιχειρήσεων ανά έτος.

3.4 Στατιστική ανάλυση χρηματοοικονομικών δεικτών

Τα Σχήματα 2Α και 2Β απεικονίζουν τα βασικά στατιστικά χαρακτηριστικά (ελάχιστη, μέγιστη και μέση τιμή) των χρηματοοικονομικών δεικτών για τις υγιείς και τις πτωχευμένες επιχειρήσεις αντίστοιχα, χρησιμοποιώντας τις ακατέργαστες (raw) τιμές των δεδομένων. Η ξεχωριστή παρουσίαση των δύο κατηγοριών επιτρέπει την άμεση σύγκριση της συμπεριφοράς των δεικτών μεταξύ υγιών και πτωχευμένων επιχειρήσεων.


Από τα διαγράμματα παρατηρείται ότι οι μέσες τιμές αρκετών δεικτών διαφοροποιούνται αισθητά μεταξύ των δύο κατηγοριών, ενώ σε ορισμένες περιπτώσεις οι πτωχευμένες επιχειρήσεις εμφανίζουν μεγαλύτερη διασπορά τιμών, όπως υποδηλώνεται από τις

αυξημένες μέγιστες τιμές. Οι διαφορές αυτές υποδεικνύουν ότι οι συγκεκριμένοι χρηματοοικονομικοί δείκτες ενδέχεται να φέρουν σημαντική πληροφορία για τη διάκριση μεταξύ υγιών και πτωχευμένων επιχειρήσεων.

Τέλος, η παρουσία μεγάλου εύρους τιμών και διαφορετικών κλιμάκων μεταξύ των δεικτών ενισχύει την ανάγκη εφαρμογής τεχνικών κανονικοποίησης, οι οποίες παρουσιάζονται στην επόμενη ενότητα.



Εικόνα 3.2 Ελάχιστες, μέγιστες και μέσες τιμές των χρηματοοικονομικών δεικτών για τις υγιείς επιχειρήσεις.



Εικόνα 3.3 Ελάχιστες, μέγιστες και μέσες τιμές των χρηματοοικονομικών δεικτών για τις πτωχευμένες επιχειρήσεις.

3.5. Συνοπτική Αποτίμηση του dataset

Συνολικά, το dataset παρέχει επαρκή και ποικίλη πληροφορία για τη μελέτη του προβλήματος πρόβλεψης χρεοκοπίας επιχειρήσεων, καθώς περιλαμβάνει τόσο χρηματοοικονομικούς δείκτες όσο και δυαδικές μεταβλητές δραστηριότητας. Η δομή του το καθιστά κατάλληλο για την εφαρμογή τεχνικών μηχανικής μάθησης και συγκριτικής αξιολόγησης μοντέλων ταξινόμησης.

Ωστόσο, από την αρχική διερεύνηση των δεδομένων προκύπτουν ορισμένες προκλήσεις, όπως η ανισορροπία μεταξύ των κλάσεων υγιών και πτωχευμένων επιχειρήσεων, καθώς και η διαφοροποίηση στις κλίμακες τιμών των μεταβλητών. Τα χαρακτηριστικά αυτά επηρεάζουν άμεσα την εκπαίδευση και την απόδοση των αλγορίθμων και καθιστούν απαραίτητη την εφαρμογή κατάλληλων τεχνικών προεπεξεργασίας και αξιολόγησης, οι οποίες αναλύονται στις επόμενες ενότητες της εργασίας.

4. Προεπεξεργασία Δεδομένων

4.1. Έλεγχος και Αντιμετώπιση Ελλειπουσών Τιμών

Στο πλαίσιο της προεπεξεργασίας των δεδομένων πραγματοποιήθηκε έλεγχος για την ύπαρξη ελλειπουσών τιμών (NaN) σε όλες τις μεταβλητές του dataset. Ο έλεγχος αυτός περιλάμβανε τόσο την καταμέτρηση όσο και τον υπολογισμό του ποσοστού ελλειπουσών τιμών ανά χαρακτηριστικό, με στόχο την πλήρη αποτύπωση της ποιότητας των δεδομένων.

Τα αποτελέσματα του ελέγχου έδειξαν ότι δεν υπάρχουν ελλείπουσες τιμές σε καμία από τις μεταβλητές του dataset, γεγονός που υποδηλώνει υψηλή πληρότητα και αξιοπιστία των δεδομένων. Συνεπώς, δεν κρίθηκε απαραίτητη η εφαρμογή τεχνικών συμπλήρωσης ελλειπουσών τιμών (imputation) ή η αφαίρεση εγγραφών, καθώς κάτι τέτοιο θα μπορούσε να αλλοιώσει αδικαιολόγητα τη διαθέσιμη πληροφορία.

Η απουσία ελλειπουσών τιμών επιτρέπει την απευθείας εφαρμογή των αλγορίθμων μηχανικής μάθησης, χωρίς την ανάγκη πρόσθετων διορθωτικών παρεμβάσεων στο συγκεκριμένο στάδιο της προεπεξεργασίας.

4.2. Κανονικοποίηση και Κλιμάκωση Χαρακτηριστικών

Για την αντιμετώπιση των διαφορετικών κλιμάκων τιμών μεταξύ των χαρακτηριστικών του dataset εφαρμόστηκε κανονικοποίηση (feature scaling) με τη μέθοδο Min–Max scaling. Η συγκεκριμένη τεχνική μετασχηματίζει τις τιμές κάθε αριθμητικού χαρακτηριστικού στο διάστημα $[0,1]$, διατηρώντας τη σχετική πληροφορία των δεδομένων.

Η κανονικοποίηση εφαρμόστηκε αποκλειστικά στα αριθμητικά χαρακτηριστικά, ενώ οι δυαδικές μεταβλητές παρέμειναν αμετάβλητες. Μετά την εφαρμογή της διαδικασίας, επιβεβαιώθηκε επιτυχώς ότι όλα τα χαρακτηριστικά βρίσκονται εντός του επιθυμητού διαστήματος τιμών.

Η εφαρμογή τεχνικών κανονικοποίησης και κλιμάκωσης χαρακτηριστικών κρίθηκε απαραίτητη, καθώς το dataset περιλαμβάνει μεταβλητές με σημαντικά διαφορετικά εύρη τιμών και μονάδες μέτρησης. Οι χρηματοοικονομικοί δείκτες παρουσιάζουν μεγάλες αποκλίσεις στην κλίμακα, γεγονός που μπορεί να οδηγήσει ορισμένα χαρακτηριστικά να κυριαρχήσουν αδικαιολόγητα στη διαδικασία εκπαίδευσης των μοντέλων.

Επιπλέον, αρκετοί από τους αλγορίθμους που χρησιμοποιούνται στην παρούσα εργασία, όπως οι k-Nearest Neighbors και οι Support Vector Machines, βασίζονται σε μετρικές απόστασης και είναι ιδιαίτερα ευαίσθητοι στην κλίμακα των χαρακτηριστικών. Χωρίς κατάλληλη κανονικοποίηση, οι αλγόριθμοι αυτοί ενδέχεται να εμφανίσουν μειωμένη απόδοση ή μεροληπτικά αποτελέσματα.

Τέλος, η κανονικοποίηση συμβάλλει στη βελτίωση της αριθμητικής σταθερότητας και της σύγκλισης των μοντέλων, διευκολύνοντας τη σύγκριση των επιδόσεων μεταξύ διαφορετικών ταξινομητών και καθιστώντας τα αποτελέσματα πιο αξιόπιστα και ερμηνεύσιμα.

5. Προτεινόμενη Μεθοδολογία

Μεθοδολογία Διαχωρισμού και Εξισορρόπησης Δεδομένων

Μετά το πρώτο βήμα που ήταν η προεπεξεργασία των δεδομένων, ακολούθησε η διαδικασία διαχωρισμού του συνόλου των δεδομένων και της αντιμετώπισης της ανισορροπίας των κλάσεων προκειμένου να διασφαλίσουμε ότι τα μοντέλα θα εκπαιδευτούν σωστά και θα αξιολογηθούν αντικειμενικά.

5.1. Χρήση του Stratified K-Fold και του Cross Validation

Για να αξιολογήσουμε τα μοντέλα και να διασφαλίσουμε την αντιπροσωπευτικότητα των κλάσεων στα σύνολα εκπαίδευσης και ελέγχου, χρησιμοποιήσαμε την τεχνική Stratified K-Fold Cross-Validation με `n_splits = 4`. Αυτή η μέθοδος διατηρεί την αναλογία των κλάσεων υγιείς και χρεοκοπημένες εταιρείες σε κάθε fold, αποφεύγοντας το overfitting και την δημιουργία τυχαίων folds με μεγάλη ανισορροπία. Λόγω της φύσης του προβλήματος (πολύ λίγες χρεοκοπημένες εταιρείες σε σχέση με τις υγιείς), η στρωματοποίηση εξασφαλίζει ότι κάθε fold διατηρεί την αρχική κατανομή των κλάσεων, αποφεύγοντας περιπτώσεις όπου ένα fold θα μπορούσε να μην περιέχει καθόλου δείγματα χρεοκοπίας. Τα δεδομένα ανακατεύτηκαν (`shuffle=True`) για να αποφύγουμε χρονικές εξάρτησης. Η διαδικασία εφαρμόστηκε ως εξής:

- 1) Ορισμός των `feature_cols` (11 δείκτες απόδοσης και δραστηριοτήτων) και του `status_col` (κατάσταση εταιρείας: 1=υγιής, 2=χρεοκοπημένη).

- 2) Δημιουργία 4 folds με τη χρήση `StratifiedKFold` από τη βιβλιοθήκη `scikit-learn`.

- 3) Για κάθε fold, υπολογίστηκε και εμφανίστηκε η κατανομή των κλάσεων στο σύνολο εκπαίδευσης (train set) και ελέγχου (test set).

5.2 Εξισορρόπηση του Συνόλου Εκπαίδευσης

Κατά την ανάλυση του συνόλου εκπαίδευσης, αντιληφθήκαμε ότι η αρχική κατανομή των κλάσεων είχε μεγάλη ανισορροπία. Πιο συγκεκριμένα, στο αρχικό training set η αναλογία του κάθε fold ήταν περίπου 42 υγιείς εταιρείες προς μία χρεοκοπημένη.

```

--- Fold Set No: 1 ---
6. Initial Train Set | Υγιείς (1): 7851, Χρεοκοπημένες (2): 186
--- Fold Set No: 2 ---
6. Initial Train Set | Υγιείς (1): 7851, Χρεοκοπημένες (2): 186
--- Fold Set No: 3 ---
6. Initial Train Set | Υγιείς (1): 7851, Χρεοκοπημένες (2): 186
--- Fold Set No: 4 ---
6. Initial Train Set | Υγιείς (1): 7851, Χρεοκοπημένες (2): 186

```

Εικόνα 5.1 Αναλογίες κάθε fold στο αρχικό training set.

Μια τέτοια ανισορροπία θα οδηγούσε το μοντέλο να προτιμά την κλάση των υγιών εταιρειών, έχοντας πολύ χαμηλή ικανότητα εντοπισμού των χρεοκοπημένων (προκατάληψη του μοντέλου υπέρ της πλειοψηφικής κλάσης) . Για την επίλυση αυτού του προβλήματος, εφαρμόστηκε Undersampling στο σύνολο εκπαίδευσης, με στόχο να επιτευχθεί αναλογία 3 υγιείς προς 1 χρεοκοπημένη.

Τα βήματα που ακολούθησαν είναι τα εξής:

1) Συνθήκη εξισορρόπησης: Εάν η αναλογία υγιών προς χρεοκοπημένες στο train set ήταν μεγαλύτερη από 3:1, τότε πραγματοποιήθηκε undersampling.

2) Μέθοδος undersampling: Τυχαία αφαίρεση υγιών δειγμάτων, ώστε να επιτευχθεί ο στόχος των 3 υγιών ανά χρεωκοπημένη εταιρεία.

3) Σημαντική παρατήρηση: Τα δείγματα που αφαιρέθηκαν από το train set δεν μεταφέρθηκαν στο test set, διατηρώντας έτσι την ακεραιότητα της διαδικασίας cross-validation.

5.3 Αποτελέσματα Εξισορρόπησης ανά Fold

Η διαδικασία εφαρμόστηκε με επιτυχία και για κάθε ένα από τα 4 folds:

1) Αρχική κατανομή (Train Set): 7.851 υγιείς, 186 χρεωκοπημένες εταιρείες.

2) Αρχική κατανομή (Test Set): 2.617 υγιείς, 62 χρεωκοπημένες εταιρείες.

3) Μετά την εξισορρόπηση (Train Set): 558 υγιείς, 186 χρεωκοπημένες (αναλογία 3 προς 1).

Σύνολο	Υγιείς Εταιρείες	Χρεοκοπημένες	Αναλογία

Initial training set	7.851	186	42:1(περίπου)
Εξισορροπημένο set	558	186	3:1
Test Set (παραμένει ως έχει)	2.617	62	42:1

Πίνακας 5.1: Η εξισορρόπηση εφαρμόστηκε αποκλειστικά στο training set κάθε fold. Το test set παρέμεινε ανέπαφο με την αρχική κατανομή των δεδομένων, ώστε η τελική αξιολόγηση να αντικατοπτρίζει την απόδοση του μοντέλου σε πραγματικές συνθήκες.

--- Fold Set No: 1 ---

6. Initial Train Set | Υγιείς (1): 7851, Χρεοκοπημένες (2): 186
6. Test Set | Υγιείς (1): 2617, Χρεοκοπημένες (2): 62
ATTENTION:Ratio > 3/1 detected.Applying undersampling for balancing
7. New ****Balanced**** Train Set | Υγιείς (1): 558, Χρεοκοπημένες (2): 186

--- Fold Set No: 2 ---

6. Initial Train Set | Υγιείς (1): 7851, Χρεοκοπημένες (2): 186
6. Test Set | Υγιείς (1): 2617, Χρεοκοπημένες (2): 62
ATTENTION:Ratio > 3/1 detected.Applying undersampling for balancing
7. New ****Balanced**** Train Set | Υγιείς (1): 558, Χρεοκοπημένες (2): 186

--- Fold Set No: 3 ---

6. Initial Train Set | Υγιείς (1): 7851, Χρεοκοπημένες (2): 186
6. Test Set | Υγιείς (1): 2617, Χρεοκοπημένες (2): 62
ATTENTION:Ratio > 3/1 detected.Applying undersampling for balancing
7. New ****Balanced**** Train Set | Υγιείς (1): 558, Χρεοκοπημένες (2): 186


--- Fold Set No: 4 ---

6. Initial Train Set | Υγιείς (1): 7851, Χρεοκοπημένες (2): 186
6. Test Set | Υγιείς (1): 2617, Χρεοκοπημένες (2): 62
ATTENTION:Ratio > 3/1 detected.Applying undersampling for balancing
7. New ****Balanced**** Train Set | Υγιείς (1): 558, Χρεοκοπημένες (2): 186

Εικόνα 5.2 Η ίδια κατανομή παρατηρήθηκε σε όλα τα folds λόγω της μεθοδολογίας stratified split, γεγονός που επιβεβαιώνει τη σταθερότητα της διαδικασίας.

5.4 Οπτικοποίηση Κατανομής Κλάσεων

Στα παρακάτω γραφήματα παρουσιάζεται η κατανομή των δειγμάτων για κάθε ένα από τα 4 folds, πριν και μετά την εφαρμογή της εξισορρόπησης:



Εικόνα 5.3 Σύγκριση πλήθους δειγμάτων ανά κλάση στο Training Set (πριν και μετά την εξισορρόπηση).

Ανάλυση Γραφήματος:

Πριν :Φαίνεται η τεράστια διαφορά μεταξύ των 7.851 υγιών και των 186 χρεωκοπημένων εταιρειών.

Μετά : Μετά το undersampling, ο αριθμός των υγιών εταιρειών μειώθηκε στις 558. Αυτή η αναλογία (3:1) παρέχει στο μοντέλο αρκετά δείγματα της πλειοψηφικής κλάσης(υγιείς) ενώ παράλληλα δίνει μεγαλύτερη βαρύτητα και στη μειονοτική κλάση των χρεωκοπημένων εταιρειών κατά τη διαδικασία της μάθησης.

5.5 Αλγόριθμοι ταξινόμησης

Σύμφωνα με τις απαιτήσεις της εργασίας, υλοποιήθηκαν και εκπαιδεύτηκαν (8) αλγόριθμοι μηχανικής μάθησης. Αναλυτικότερα, αξιοποιήθηκαν τα (7) μοντέλα που υποδεικνύονται στην εκφώνηση ενώ ως 8ο επιλέχθηκε ο Gradient Boosting Classifier της βιβλιοθήκης scikit-learn.

Η επιλογή του συγκεκριμένου αλγόριθμου έγινε διότι αποτελεί μια μέθοδο ενίσχυσης (boosting), η οποία χτίζει διαδοχικά δέντρα αποφάσεων για τη διόρθωση των σφαλμάτων

των προηγούμενων. Προτιμήθηκε έναντι άλλων αλγορίθμων, καθώς η βιβλιογραφία το αναδεικνύει ως μία από τις πιο ισχυρές τεχνικές συνόλου (ensemble methods), ικανή να επιτύχει υψηλή ακρίβεια και να μειώσει το σφάλμα μεροληψίας (bias) και διακύμανσης (variance) σε πολύπλοκα δεδομένα (Hastie et al., 2009).

Ακολουθεί η λίστα των αλγορίθμων που αξιοποιήθηκαν:

1. Linear Discriminant Analysis (LDA)
2. Logistic Regression
3. Decision Trees
4. Random Forests
5. k-Nearest Neighbors (k-NN)
6. Naïve Bayes
7. Support Vector Machines (SVM)
8. Gradient Boosting Classifier (μοντέλο επιλογής)

Τεχνικές Ρυθμίσεις (Hyperparameters)

Για την παραμετροποίηση των αλγορίθμων χρησιμοποιήθηκαν κυρίως οι προεπιλεγμένες ρυθμίσεις (default hyperparameters), με στοχευμένες παρεμβάσεις για την τεχνική αρτιότητα της εκπαίδευσης:

- Σταθερότητα: Σε όλους τους στοχαστικούς αλγορίθμους (Decision Tree, Random Forest, SVM, Gradient Boosting) ορίστηκε σταθερή τυχαία τιμή (random_state=2025) για τη διασφάλιση της αναπαραγωγιμότητας των αποτελεσμάτων.
- Σύγκλιση: Στη Λογιστική Παλινδρόμηση αυξήθηκε το όριο επαναλήψεων (max_iter=2000), ώστε να επιτευχθεί η σύγκλιση του αλγορίθμου βελτιστοποίησης.
- Πιθανοφάνεια: Στα SVM ενεργοποιήθηκε η δυνατότητα υπολογισμού πιθανοτήτων (probability=True), η οποία είναι απαραίτητη για τον υπολογισμό της μετρικής ROC-AUC.

Στο πλαίσιο της παρούσας μελέτης δεν εφαρμόστηκε διαδικασία αυτόματης βελτιστοποίησης υπερπαραμέτρων (hyperparameter optimization). Η επιλογή αυτή είναι συνειδητή και συνδέεται άμεσα με τον βασικό στόχο της εργασίας, ο οποίος είναι η συγκριτική αξιολόγηση διαφορετικών αλγορίθμων ταξινόμησης υπό ενιαίες και ελεγχόμενες συνθήκες εκπαίδευσης. Οι αλγόριθμοι εκπαιδεύτηκαν κυρίως με τις προεπιλεγμένες ρυθμίσεις τους, με περιορισμένες και τεκμηριωμένες παρεμβάσεις όπου κρίθηκε απαραίτητο για λόγους σταθερότητας, σύγκλισης και υπολογισμού των μετρικών αξιολόγησης. Με τον τρόπο αυτό διασφαλίζεται ότι οι παρατηρούμενες διαφορές στην απόδοση των μοντέλων αποδίδονται κυρίως στις εγγενείς ιδιότητές τους και όχι σε εκτεταμένη διαδικασία παραμετροποίησης.

5.6 Διαδικασία Εκπαίδευσης και Αξιολόγησης

Με στόχο την εξασφάλιση της εγκυρότητας των αποτελεσμάτων και την αποφυγή της υπερπροσαρμογής (overfitting), ακολουθήθηκε μια δομημένη πειραματική διαδικασία, σύμφωνη με τις βέλτιστες πρακτικές της βιβλιογραφίας. Συγκεκριμένα, υιοθετήθηκε η μέθοδος Stratified K-Fold Cross-Validation, προκειμένου:

- να διατηρείται η αναλογία των κλάσεων σε κάθε fold μέσω στρωματοποιημένης δειγματοληψίας,
- να διασφαλίζεται η αναπαραγωγιμότητα των αποτελεσμάτων μέσω σταθερής αρχικοποίησης (`random_state = 2025`). Επομένως, έχουμε σταθερά τα ίδια αποτελέσματα. Ενώ με οποιοδήποτε άλλο `random_state` θα πάρουμε διαφορετικά αποτελέσματα και ενδεχομένως άλλο καλύτερο μοντέλο στη μητρική F1 score. Ο λόγος είναι ότι τα 3 πρώτα σε F1 score μοντέλα (SVM, Gradient Boosting, Random Forest) είναι σχεδόν ισαδύναμα μεταξύ τους.
- Η διαδικασία υλοποιήθηκε με 4 folds (`n_splits = 4`) και τυχαία αναδιάταξη των δεδομένων (`shuffle = True`). Με τον τρόπο αυτό, το σύνολο δεδομένων χωρίστηκε επαναληπτικά σε σύνολα εκπαίδευσης (training set) και ελέγχου (test set), έτσι ώστε κάθε παρατήρηση να χρησιμοποιηθεί μία φορά ως σύνολο ελέγχου και τις υπόλοιπες ως σύνολο εκπαίδευσης.

Σε κάθε fold, εξετάστηκε η κατανομή των κλάσεων στο σύνολο εκπαίδευσης. Όταν η αναλογία υγιών προς χρεοκοπημένες επιχειρήσεις υπερέβαινε το όριο 3:1, εφαρμόστηκε τεχνική undersampling στην πλειοψηφική κλάση, με τυχαία αφαίρεση υγιών επιχειρήσεων, ώστε η τελική αναλογία στο training set να είναι 3 προς 1. Η διαδικασία εξισορρόπησης εφαρμόστηκε αποκλειστικά στο σύνολο εκπαίδευσης, ενώ το σύνολο ελέγχου διατηρήθηκε στην αρχική του κατανομή, σύμφωνα με τις οδηγίες της εκφώνησης.

Για λόγους συμβατότητας με τις βιβλιοθήκες μηχανικής μάθησης που χρησιμοποιήθηκαν, οι ετικέτες κλάσεων μετατράπηκαν σε δυαδική μορφή, όπου οι υγιείς επιχειρήσεις κωδικοποιήθηκαν ως 0 και οι χρεοκοπημένες ως 1.

Για κάθε fold και για κάθε μοντέλο, πραγματοποιήθηκε εκπαίδευση στο σύνολο εκπαίδευσης και αξιολόγηση τόσο στο training όσο και στο test set. Η απόδοση των μοντέλων αξιολογήθηκε μέσω των μετρικών Accuracy, Precision, Recall, F1-score και ROC-AUC, ενώ παράλληλα υπολογίστηκαν οι αντίστοιχοι πίνακες σύγχυσης (confusion matrices). Όλα τα αποτελέσματα καταγράφηκαν σε ενιαίο πίνακα δεδομένων, ώστε να καταστεί δυνατή η συγκεντρωτική ανάλυση και η συγκριτική αξιολόγηση των μοντέλων.

Στη συνέχεια, παρουσιάζονται αναλυτικά οι βασικές συνιστώσες της πειραματικής διαδικασίας, τόσο ως προς τη μεθοδολογία που ακολουθήθηκε όσο και ως προς τις επιλογές που έγιναν για την αντιμετώπιση ιδιαιτεροτήτων του προβλήματος. Αναλυτικότερα:

A. Επαναληπτική Διασταυρούμενη Επικύρωση (Stratified K-Fold Cross-Validation)

Η επιλογή της μεθόδου της επαναληπτικής διασταυρούμενης επικύρωσης αιτιολογείται από τη βιβλιογραφία. Σύμφωνα με τους Hastie et al. (2009), η μέθοδος αυτή επιτρέπει τη χρήση του συνόλου των δεδομένων τόσο για εκπαίδευση όσο και για έλεγχο, μειώνοντας τη διακύμανση της εκτίμησης του σφάλματος πρόβλεψης. Η χρήση της στρωματοποιημένης εκδοχής (stratified) διασφαλίζει ότι κάθε fold διατηρεί την αρχική αναλογία των κλάσεων (υγιείς/πτωχευμένες), γεγονός ιδιαίτερα κρίσιμο σε προβλήματα με ανισόρροπα δεδομένα (Pedregosa et al., 2011).

Δεδομένου ότι το πρόβλημα της πρόβλεψης πτώχευσης χαρακτηρίζεται από έντονη ανισορροπία κλάσεων, η διαδικασία διασταυρούμενης επικύρωσης συμπληρώθηκε με κατάλληλη στρατηγική εξισορρόπησης των δεδομένων.

B. Στρατηγική Αντιμετώπισης Ανισόρροπων Δεδομένων (Undersampling)

Η ανισορροπία των κλάσεων (class imbalance) αποτελεί βασική πρόκληση σε προβλήματα πρόβλεψης πτώχευσης. Για την αντιμετώπισή της, ενσωματώθηκε δυναμική στρατηγική υποδειγματοληψίας (undersampling), η οποία εφαρμόζεται ξεχωριστά σε κάθε fold.

Συγκεκριμένα, σε κάθε επανάληψη ελέγχεται η αναλογία μεταξύ υγιών και πτωχευμένων επιχειρήσεων στο training set. Όταν η αναλογία υπερβαίνει το όριο 3:1, το δείγμα της πλειοψηφικής κλάσης (υγιείς επιχειρήσεις) μειώνεται τυχαία έως ότου επιτευχθεί η επιθυμητή αναλογία. Η προσέγγιση αυτή υποστηρίζεται από τους He & Garcia (2009), οι οποίοι επισημαίνουν ότι η εξισορρόπηση των κλάσεων μειώνει την προκατάληψη των αλγορίθμων προς την πλειοψηφική κλάση και βελτιώνει την ικανότητα εντοπισμού των σπάνιων περιπτώσεων.

Παρότι η χρήση undersampling κρίθηκε απαραίτητη για την αντιμετώπιση της ανισορροπίας των κλάσεων, αποτελεί έναν περιορισμό της μεθοδολογίας, καθώς οδηγεί σε απώλεια πληροφορίας από την πλειοψηφική κλάση.

Η απώλεια αυτή ενδέχεται να επηρεάζει τη γενικευτική ικανότητα των μοντέλων.

Μελλοντικά, θα μπορούσαν να εξεταστούν εναλλακτικές τεχνικές εξισορρόπησης, όπως μέθοδοι υπερδειγματοληψίας (π.χ. SMOTE) ή συνδυαστικές προσεγγίσεις.

Γ. Μετασχηματισμός Στόχων (Target Mapping)

Για τη συμβατότητα με τις βιβλιοθήκες της Scikit-Learn, πραγματοποιήθηκε ανακατανομή των τιμών (mapping): οι υγιείς εταιρείες (1) αντιστοιχίστηκαν στο 0 και οι πτωχευμένες (2) στο 1. Η μετατροπή αυτή φυσικά δεν επηρεάζει την ερμηνεία των αποτελεσμάτων, αλλά είναι απαραίτητη για τη σωστή λειτουργία των αλγορίθμων.

Δ. Μετρικές Αξιολόγησης και Καταγραφή

Η αξιολόγηση της απόδοσης των μοντέλων πραγματοποιήθηκε τόσο στο σύνολο εκπαίδευσης όσο και στο σύνολο ελέγχου με τη χρήση του Πίνακα Σύγχυσης (Confusion Matrix). Όπως επισημαίνει ο Fawcett (2006), σε προβλήματα με ανισόρροπα δεδομένα η συνολική ακρίβεια (accuracy) μπορεί να είναι παραπλανητική. Για τον λόγο αυτό, δόθηκε έμφαση σε μετρικές που αποτυπώνουν καλύτερα την ικανότητα εντοπισμού των πτωχευμένων επιχειρήσεων.

Συγκεκριμένα, καταγράφηκαν:

- True Positives (TP) και False Negatives (FN), για την αξιολόγηση της ικανότητας εντοπισμού των περιπτώσεων πτώχευσης,
- Accuracy, Precision, Recall και F1-score, με το F1-score να χρησιμοποιείται ως βασικό κριτήριο σύγκρισης των μοντέλων,
- ROC-AUC score, ως συμπληρωματικός δείκτης της διακριτικής ικανότητας των ταξινομητών.

Όλα τα αποτελέσματα αποθηκεύτηκαν σε ενιαίο αρχείο δεδομένων, το οποίο χρησιμοποιήθηκε για τη συγκριτική ανάλυση που παρουσιάζεται στο κεφάλαιο των Πειραματικών Αποτελεσμάτων.

Κεντρική Δομή Εκτέλεσης (Outer Loop)

Ο κώδικας οργανώνεται γύρω από έναν κεντρικό επαναληπτικό βρόχο, ο οποίος διατρέχει διαδοχικά τα τέσσερα υποσύνολα δεδομένων που προκύπτουν από τη διαδικασία διασταυρούμενης επικύρωσης. Σε κάθε επανάληψη του βρόχου:

- δημιουργούνται τα αντίστοιχα σύνολα εκπαίδευσης και ελέγχου,
- πραγματοποιούνται οι απαραίτητες προσαρμογές στα δεδομένα εκπαίδευσης,
- προετοιμάζονται οι τελικοί πίνακες εισόδου και οι ετικέτες στόχου για την εκπαίδευση των μοντέλων.

Η συγκεκριμένη δομή επιτρέπει την ανεξάρτητη εκτέλεση κάθε fold, διευκολύνοντας τον έλεγχο της γενικευτικής ικανότητας των μοντέλων.


Εκπαίδευση και Υπολογισμός Μετρικών (Inner Loop)

Εντός κάθε επανάληψης του κεντρικού βρόχου, ένας δεύτερος επαναληπτικός μηχανισμός αναλαμβάνει την εκπαίδευση των οκτώ αλγορίθμων μηχανικής μάθησης. Για κάθε μοντέλο:

- πραγματοποιείται εκπαίδευση στα δεδομένα εκπαίδευσης,
- παράγονται προβλέψεις τόσο για το training όσο και για το test set,
- υπολογίζονται οι προβλεπόμενες ετικέτες και οι αντίστοιχες πιθανότητες όπου αυτό απαιτείται,

- υπολογίζονται οι μετρικές αξιολόγησης που έχουν οριστεί στη μεθοδολογία.

Κατά τη διάρκεια της εκτέλεσης, παράγονται πίνακες σύγχυσης, οι οποίοι χρησιμοποιούνται αποκλειστικά για τον έλεγχο της ορθής λειτουργίας της πειραματικής διαδικασίας.



Εικόνα 5.4 Ενδεικτικός Πίνακας Σύγχυσης για το μοντέλο *Linear Discriminant Analysis* (LDA), όπως παράγεται αυτόματα κατά την εκτέλεση του κώδικα.

Η δομή των επαναλήψεων οδηγεί συνολικά στη δημιουργία 64 ανεξάρτητων πειραματικών καταγραφών, οι οποίες αντιστοιχούν σε όλους τους συνδυασμούς folds, μοντέλων και συνόλων αξιολόγησης.

Καταγραφή και Αποθήκευση Αποτελεσμάτων

Τα αποτελέσματα κάθε πειραματικής εκτέλεσης αποθηκεύονται άμεσα σε δομή pandas DataFrame, μαζί με πληροφορίες που αφορούν το μοντέλο, το σύνολο αξιολόγησης και τα αντίστοιχα μεγέθη απόδοσης. Με την ολοκλήρωση της εκτέλεσης του σεναρίου, το σύνολο των αποτελεσμάτων εξάγεται σε αρχείο balancedDataOutcomes.csv.

Το αρχείο αυτό χρησιμοποιήθηκε ως ενιαία βάση δεδομένων για τη μεταγενέστερη συγκεντρωτική ανάλυση και την παραγωγή των γραφημάτων που παρουσιάζονται στο κεφάλαιο των Πειραματικών Αποτελεσμάτων.

5.7 Χαρακτηριστικά Εισόδου και Υπολογιστικό Περιβάλλον

Επιλογή Χαρακτηριστικών (Feature Selection)

Για την εκπαίδευση των μοντέλων χρησιμοποιήθηκε το σύνολο των διαθέσιμων χαρακτηριστικών που προέκυψαν μετά το στάδιο της προεπεξεργασίας των δεδομένων. Συγκεκριμένα, στους αλγορίθμους τροφοδοτήθηκαν και οι 11 μεταβλητές του συνόλου δεδομένων, οι οποίες περιλαμβάνουν 8 χρηματοοικονομικούς δείκτες και 3 δείκτες δραστηριότητας.

Η επιλογή αυτή έγινε με σκοπό την αξιοποίηση του συνόλου της διαθέσιμης πληροφορίας, χωρίς περαιτέρω μείωση διαστάσεων ή επιλογή υποσυνόλου χαρακτηριστικών, ώστε να αξιολογηθεί η απόδοση των μοντέλων στο πλήρες πληροφοριακό περιεχόμενο του dataset.

Λογισμικό και Βιβλιοθήκες (Software Stack)

Η ανάπτυξη και η εκτέλεση του κώδικα πραγματοποιήθηκαν στο περιβάλλον νέφους Google Colab, αξιοποιώντας την υπολογιστική ισχύ και τις παρεχόμενες βιβλιοθήκες της πλατφόρμας. Η υλοποίηση βασίστηκε στη γλώσσα προγραμματισμού Python και στις ακόλουθες βασικές βιβλιοθήκες ανοικτού κώδικα:

- Scikit-Learn: για την υλοποίηση των αλγορίθμων μηχανικής μάθησης, την προεπεξεργασία των δεδομένων (MinMaxScaler) και τον υπολογισμό των μετρικών αξιολόγησης.
- Pandas και NumPy: για τη διαχείριση, τον χειρισμό και την επεξεργασία των δεδομένων σε μορφή πινάκων.
- Matplotlib: για την παραγωγή γραφικών απεικονίσεων, όπως οι πίνακες σύγκρισης.

Η σύγκριση των μοντέλων βασίστηκε στη μέση απόδοση των μετρικών στο test set, όπως αυτή προκύπτει από τη διαδικασία Stratified K-Fold Cross-Validation ($k=4$). Η προσέγγιση αυτή επιτρέπει την εξαγωγή πιο αξιόπιστων συμπερασμάτων, καθώς μειώνει την επίδραση τυχαίων διαχωρισμών των δεδομένων και ενισχύει τη στατιστική σταθερότητα των αποτελεσμάτων.

6. Πειραματικά αποτελέσματα

6.1 Επεξεργασία Αρχείου Αποτελεσμάτων

Μετά την ολοκλήρωση της εκτέλεσης του κώδικα και την παραγωγή του αρχείου `balancedDataOutcomes.csv`, το αρχείο μετατράπηκε σε μορφή Excel (.xlsx) ώστε να καταστεί δυνατή η περαιτέρω ανάλυση των αποτελεσμάτων.

Το αρχείο περιείχε για κάθε ταξινομητή και για κάθε fold τις τιμές των True Positives (TP), True Negatives (TN), False Positives (FP), False Negatives (FN), καθώς και την μετρική ROC-AUC.

Υπολογισμός Μετρικών Απόδοσης

Χρησιμοποιώντας αποκλειστικά τις τιμές του confusion matrix και τους τύπους που παρουσιάζονται στη σελίδα της Wikipedia για το confusion matrix, προστέθηκαν στο αρχείο Excel οι ακόλουθες μετρικές:

- Accuracy, η οποία εκφράζει το συνολικό ποσοστό σωστών προβλέψεων.
- Precision, η οποία δείχνει το ποσοστό των σωστά προβλεπόμενων χρεωκοπημένων εταιρειών επί των συνολικών προβλέψεων χρεωκοπίας.
- Recall, η οποία εκφράζει την ικανότητα του μοντέλου να εντοπίζει τις εταιρίες που πράγματι κηρύσσουν χρεωκοπία.
- F1 Score, το οποίο συνδυάζει τις μετρικές Precision και Recall και θεωρείται ιδιαίτερα κατάλληλο για προβλήματα με ανισόρροπα δεδομένα.

Επιπλέον, προστέθηκαν δύο συμπληρωματικές μετρικές:

- Specificity, η οποία μετρά την ικανότητα του μοντέλου να αναγνωρίζει σωστά τις υγιείς εταιρείες.
- Balanced Accuracy, η οποία αποτελεί τον μέσο όρο της Recall και της Specificity και περιέχει μια πιο αντικειμενική εικόνα της απόδοσης σε ανισόρροπα σύνολα δεδομένων.

6.2 Σύγκριση μοντέλων με Pivot Tables

Για τη σύγκριση των μοντέλων χρησιμοποιήθηκαν Pivot Tables του Excel. Συγκεκριμένα, υπολογίστηκε ο μέσος όρος του F1 Score για κάθε ταξινομητή στο test set, λαμβάνοντας υπόψη όλα τα folds της διαδικασίας cross-validation.

Η χρήση Pivot Tables επέτρεψε την άμεση και αξιόπιστη σύγκριση της απόδοσης των διαφορετικών μοντέλων, χωρίς την ανάγκη επιπλέον υπολογισμών.

6.3 Οπτικοποίηση Αποτελεσμάτων

Με βάση τα δεδομένα των Pivot Tables δημιουργήθηκαν γραφικές παραστάσεις τύπου bar chart, οι οποίες απεικονίζουν τον μέσο όρο του F1 Score για κάθε ταξινομητή στο test set. Τα γραφήματα αυτά διευκολύνουν τον εντοπισμό του μοντέλου με την καλύτερη συνολική επίδοση.

Το μοντέλο με την μεγαλύτερη τιμή F1 Score θεωρήθηκε ως το βέλτιστο για το συγκεκριμένο πρόβλημα, καθώς παρουσιάζει την καλύτερη ισορροπία μεταξύ Precision και Recall.

Τα αποτελέσματα έδειξαν ότι το μοντέλο Random Forest παρουσίασε το υψηλότερο μέσο F1 Score (περίπου 0,20) με το Support Vector Machine (SVM) να ακολουθεί σε πολύ μικρή απόσταση. Τα υπόλοιπα μοντέλα εμφάνισαν χαμηλότερες τιμές F1 Score, γεγονός που υποδηλώνει μειωμένη ικανότητα ταυτόχρονης επίτευξης υψηλής Precision και Recall.

6.4 Έλεγχος Περιορισμών Απόδοσης

Στη συνέχεια πραγματοποιήθηκε έλεγχος των περιορισμών απόδοσης που τέθηκαν στη εκφώνηση. Συγκεκριμένα, εξετάστηκε αν τα μοντέλα επιτυγχάνουν Recall τουλάχιστον 60% για την ανίχνευση των χρεωκοπημένων εταιρειών και Specificity τουλάχιστον 70% για την σωστή αναγνώριση των υγιών εταιρειών.

Στον πίνακα παρουσιάζονται οι μέσες τιμές Recall και Specificity στο test set, όπως προέκυψαν από τη διαδικασία Stratified K-Fold Cross-Validation. Παρατηρείται ότι όλα τα μοντέλα ξεπερνούν το όριο του 70% ως προς τη Specificity, ωστόσο καμία τεχνική δεν επιτυγχάνει Recall μεγαλύτερο ή ίσο του 60%. Συνεπώς, δεν υπάρχει ταξινομητής που να ικανοποιεί ταυτόχρονα και τους δύο περιορισμούς, γεγονός που καθιστά το πρόβλημα ιδιαίτερα απαιτητικό. Επομένως, δεν υπάρχει μοντέλο που να πληροί πλήρως τα προκαθορισμένα κριτήρια επιτυχίας για την ανίχνευση τόσο των χρεωκοπημένων όσο και των υγιών εταιριών.


Training or test set	Test	
Ετικέτες γραμμής ▾	Μέσος όρος από Μετρική 1 - Specificity	Μέσος όρος από Recall
Decision Tree	0,809801299	0,475806452
Gradient Boosting	0,91173099	0,483870968
KNN	0,891956439	0,504032258
LDA	0,929308368	0,415322581
Logistic Regression	0,941727169	0,350806452
Naive Bayes	0,876098586	0,524193548
Random Forest	0,925487199	0,451612903
SVM	0,942395873	0,370967742
Γενικό Άθροισμα	0,90356324	0,447076613

Εικόνα 6.1 Οι μέσες τιμές Recall και Specificity στο test set

6.5 Στατιστική Εγκυρότητα Σύγκρισης Μοντέλων

Αναφορικά με τη στατιστική εγκυρότητα των αποτελεσμάτων και τη σύγκριση των εξεταζόμενων τεχνικών ταξινόμησης, διευκρινίζεται ότι τα συμπεράσματα της παρούσας εργασίας δεν βασίζονται σε μία μεμονωμένη εκτέλεση (single run), αλλά σε αξιολόγηση μέσω Stratified K-Fold Cross-Validation ($k = 4$). Για κάθε ταξινομητή υπολογίστηκαν οι μετρικές απόδοσης σε τέσσερα διαφορετικά υποσύνολα ελέγχου και η σύγκριση πραγματοποιήθηκε με βάση τους μέσους όρους των μετρικών, και ειδικότερα του F1-score.

Η χρήση cross-validation μειώνει τη διακύμανση των αποτελεσμάτων και καθιστά τη σύγκριση πιο αξιόπιστη. Με βάση τα αποτελέσματα στο test set, το μοντέλο Random Forest εμφανίζει τη μεγαλύτερη μέση τιμή F1-score, με το Support Vector Machine (SVM) να ακολουθεί σε πολύ μικρή απόσταση. Συνεπώς, το Random Forest μπορεί να θεωρηθεί το καλύτερο μοντέλο για το συγκεκριμένο πρόβλημα, χωρίς όμως η διαφορά του να είναι μεγάλη σε σχέση με τα υπόλοιπα μοντέλα.



Εικόνα 6.2. Το καλύτερο μοντέλο, αυτό με το υψηλότερο μέσο όρο στο F1 Score

7. Συμπεράσματα

Η παρούσα εργασία έχει ως αντικείμενο την ανάπτυξη και συγκριτική αξιολόγηση μοντέλων Μηχανικής Μάθησης για την πρόβλεψη της εταιρικής χρεοκοπίας. Η μεθοδολογία που ακολουθήθηκε βασίστηκε σε πρότυπα αξιολόγησης (Stratified K-Fold Cross-Validation) και έδωσε ιδιαίτερη έμφαση στην αντιμετώπιση της έντονης ανισορροπίας των κλάσεων μέσω της τεχνικής υποδειγματοληψίας (undersampling).

Από την ανάλυση των πειραματικών αποτελεσμάτων προέκυψαν τα ακόλουθα βασικά συμπεράσματα:

1. **Ανάδειξη Βέλτιστου Μοντέλου:** Μεταξύ των οκτώ αλγορίθμων που εξετάστηκαν, ο **Random Forest** αναδείχθηκε ως ο αποδοτικότερος, επιτυγχάνοντας το υψηλότερο μέσο F1-score (περίπου 0.20). Ακολούθησε σε πολύ κοντινή απόσταση το Support Vector Machine (SVM). Η υπεροχή αυτών των μοντέλων έναντι των απλούστερων γραμμικών μεθόδων επιβεβαιώνει τη μη γραμμική φύση των οικονομικών δεδομένων και την ανάγκη χρήσης ισχυρότερων υπολογιστικών εργαλείων.
2. **Χαμηλές Επιδόσεις και Ανισορροπία Δεδομένων:** Παρά την εφαρμογή της διαδικασίας της εξισορρόπησης, οι απόλυτες τιμές του F1-score παρέμειναν σε χαμηλά επίπεδα για όλα τα μοντέλα. Το γεγονός αυτό υποδηλώνει είτε ότι οι διαθέσιμοι δείκτες δεν επαρκούν για τον πλήρη διαχωρισμό των κλάσεων, είτε ότι η μείωση των δεδομένων λόγω undersampling επηρέασε τη γενικευτική ικανότητα των μοντέλων.
3. **Μη Ικανοποίηση Επιχειρησιακών Περιορισμών:** Σχετικά με τους στόχους απόδοσης που τέθηκαν, διαπιστώθηκε ότι ενώ η Specificity (ικανότητα σωστής αναγνώρισης υγιών εταιρειών) ξεπέρασε το 70% σε όλα τα μοντέλα, κανένας ταξινομητής δεν κατάφερε να επιτύχει Recall (ικανότητα εντοπισμού χρεωκοπημένων) άνω του 60%. Αυτό καταδεικνύει την εγγενή δυσκολία αύξησης της ευαισθησίας χωρίς την ταυτόχρονη αύξηση των ψευδώς θετικών αποτελεσμάτων.
4. **Περιορισμοί του Dataset:** Το dataset που χρησιμοποιείται στην παρούσα εργασία δεν είναι αναγνωρισμένο ευρέως ως δημόσιο benchmark dataset στη διεθνή βιβλιογραφία. Παρόλο που υπάρχουν διαθέσιμα δημόσια σύνολα δεδομένων για πρόβλεψη χρεοκοπίας επιχειρήσεων (π.χ. Taiwanese Bankruptcy Prediction και Polish bankruptcy datasets από UCI Machine Learning Repository), το αρχείο *Dataset2Use_Assignment1.xlsx* που μας έχει δοθεί αποτελεί ξεχωριστό dataset για εκπαιδευτικούς σκοπούς και δεν βρέθηκαν δημοσιευμένες μελέτες με άμεσα συγκρίσιμα αποτελέσματα. Επομένως, δεν ήταν δυνατή η σύγκριση των επιδόσεων των μοντέλων της παρούσας εργασίας με αποτελέσματα άλλων ερευνητών για το ίδιο dataset.

Συνοψίζοντας, η εργασία κατέδειξε ότι η πρόβλεψη της πτώχευσης είναι ένα εξαιρετικά σύνθετο πρόβλημα. Αν και ο αλγόριθμος Random Forest προσφέρει την καλύτερη

ισορροπία μεταξύ ακρίβειας και ανάκλησης στο συγκεκριμένο πλαίσιο, για την επίτευξη υψηλότερων επιδόσεων θα απαιτούνταν πιθανότατα η χρήση πιο εξελιγμένων τεχνικών εξισορρόπησης (π.χ. SMOTE) ή ο εμπλουτισμός των δεδομένων με επιπλέον ποιοτικούς δείκτες.

8. Βιβλιογραφικές αναφορές

1. Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8), 861-874.
2. Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer Science & Business Media.
3. He, H., & Garcia, E. A. (2009). Learning from Imbalanced Data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263–1284.
4. Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
5. Altman, E. I. (1968). Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. *The Journal of Finance*, 23(4), 589-609.
6. Ohlson, J. A. (1980). Financial ratios and the probabilistic prediction of bankruptcy. *Journal of Accounting Research*, 109-131.
7. Min, J. H., & Lee, Y. C. (2005). Bankruptcy prediction using support vector machine with optimal choice of kernel function parameters. *Expert Systems with Applications*, 28(4), 603-614.
8. Zhang, Y., & Ma, X. (2021). Comparative analysis of ensemble learning for bankruptcy prediction. *International Journal of Economics and Finance*.
9. Δασκαλόπουλος, Ε. (2021). *Η πρόβλεψη της πτώχευσης των ελληνικών επιχειρήσεων με τη χρήση αριθμοδεικτών*. Διπλωματική Εργασία, Πανεπιστήμιο Πειραιώς.
10. Βρίκου, Ζ. (2021). *Πρόβλεψη οικονομικής δυσχέρειας με τη χρήση λογιστικών δεδομένων*. Διπλωματική Εργασία, Πανεπιστήμιο Μακεδονίας.